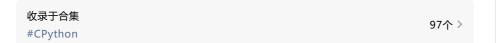
## 《源码探秘 CPython》38. 字典是如何扩容的?

原创 古明地觉 古明地觉的编程教室 2022-03-01 08:30







这里先来补充一个之前没有说的点,PyDictObject里面有一个ma\_used字段,它维护的是键值对的数量,充当ob\_size;而在PyDictKeysObject里面有一个dk\_nentries,它维护键值对数组中已使用的entry数量,而这个entry又可以理解为键值对。那么问题来了,这两者有什么区别呢?

如果不涉及元素的删除,那么两者的值会是一样的。而一旦删除某个已存在的key,那么ma\_used会减1,而dk\_nentries则保持不变。

首先ma\_used<mark>减1</mark>表示键值对数量相比之前少了一个,这显然符合我们在Python里面使用字典时的表现;但我们知道元素的删除其实是伪删除,会将对应的entry从active态变成dummy态,然而entry的总数量并没有改变。

也就是说,ma\_used其实等于active态的entry总数;如果将dk\_nentries减去dummy态的entry总数,那么得到的就是ma\_used。

所以这就是两者的区别,我们对一个字典使用**len函数**,获取的也是ma\_used,而不是dk\_nentries。

```
1 static Py_ssize_t
2 dict_length(PyDictObject *mp)
3 {
4    return mp->ma_used;
5 }
```

这算是一个遗漏的点,这里补充一下,然后来看看字典是如何扩容的。

## **字典的**扩容

当已使用entry的数量达到了总容量的2/3时,会发生扩容。但解释器要怎么判断entry数量是否达到了总容量的2/3呢?

我们说Python在早期只有一个键值对数组,这个键值对数组不仅要存储具体的entry,还要完成哈希索引数组的功能。本来这个方式很简单,但是内存浪费严重,于是后面Python官方就将一个数组拆成两个数组来实现。

不是说只能用2/3吗?那我给键值对数组就申请容量的2/3,并且只负责存储键值对。至于索引,则由哈希索引数组来体现。通过将key映射成索引,可以找到哈希索引数组中指定的槽,再根据槽里面存储的值,可以在键值对数组中找到指定entry。

因此减少内存开销的核心就在于,减少键值对数组的浪费。

所以哈希索引数组的长度就可以看成是哈希表的容量,而键值对数组的长度本身就是哈希索引数组的2/3、或者说容量的2/3。那么很明显,当键值对数组满了,就说明当前的哈希表要扩容了。

```
2 #define GROWTH_RATE(d) ((d)->ma_used*3)
```

并且扩容的时候,新哈希表的容量为**大于等于ma\_used\*3**的最小2的幂次方。假设当前ma\_used\*3等于63,那么扩容之后的容量就是64,也就是2的8次方。

总而言之新哈希表的容量不能小于ma\_used\*3,并且等于2的幂次方,基于这两个限制条件,去取最小值。

并且注意是ma\_used\*3,不是dk\_nentries。因为dk\_nentries还包含了dummy态的entry,但是哈希表在扩容的时候会将其丢弃,只保留active态的entry。所以扩容时,新哈希表的长度取决于ma\_used。

然后我们来看看扩容对应的具体逻辑。

所以核心藏在dictresize函数里面。

```
1 static int
2 dictresize(PyDictObject *mp, Py_ssize_t minsize)
   //新的哈希表容量, 以及当前老哈希表的键值对个数
    Py ssize t newsize, numentries;
5
6
     //老哈希表的ma_keys
    PyDictKeysObject *oldkeys;
7
8
    //老哈希表的ma_values
    PyObject **oldvalues;
9
10 //老哈希表的dk_entries, 新哈希表的dk_entries
     PyDictKeyEntry *oldentries, *newentries;
11
12
    /* 确定哈希表的大小*/
13
    //PyDict_MINSIZE等于8, 所以哈希表的容量最少是8
14
    //然后不断左移一位, 也就是乘上2
15
    //因为哈希表的容量必须是2的幂次方
    for (newsize = PyDict_MINSIZE;
17
    //直到newsize大于等于minsize为止
18
    //这个minsize就是我们传递的参数, 等于ma_used*3
19
         newsize < minsize && newsize > 0;
20
         newsize <<= 1)
21
22
    if (newsize <= 0) {</pre>
23
        PyErr_NoMemory();
24
25
        return -1;
26
27
     //获取老哈希表的ma_keys
28
29
     oldkeys = mp->ma_keys;
30
    /* 创建能够容纳newsize个entry的内存空间 */
31
     mp->ma_keys = new_keys_object(newsize);
32
33    if (mp->ma_keys == NULL) {
       //把老哈希表的key拷贝过去
34
        mp->ma_keys = oldkeys;
35
        return -1;
36
37
    assert(mp->ma_keys->dk_usable >= mp->ma_used);
39 //如果之前设置了探测函数
```

```
//那么也作为新哈希表的探测函数
40
       if (oldkeys->dk_lookup == lookdict)
41
           mp->ma_keys->dk_lookup = lookdict;
42
43
       //获取当前键值对的个数
44
45
       numentries = mp->ma_used;
       //获取老哈希表的dk entries
46
       oldentries = DK_ENTRIES(oldkeys);
47
      //获取新哈希表的dk entries
48
       newentries = DK_ENTRIES(mp->ma_keys);
49
      //获取新哈希表的ma_values
50
      oldvalues = mp->ma_values;
51
       //如果oldvalues不为NULL, 说明是一个split table
52
      //分离表的特点是key是字符串
53
       //并且分离表不支持扩容, 如果想扩容
54
55
       //那么需要把split table转换成combined table
      if (oldvalues != NULL) {
56
           for (Py_ssize_t i = 0; i < numerities; i++) {</pre>
57
              assert(oldvalues[i] != NULL);
58
59
          //获取ma_values数组里面的元素
          //依次设置到PyDictKeyEntry对象里面去
60
              PyDictKeyEntry *ep = &oldentries[i];
61
              PyObject *key = ep->me_key;
62
63
              Py_INCREF(key);
              newentries[i].me_key = key;
64
              newentries[i].me_hash = ep->me_hash;
65
              newentries[i].me_value = oldvalues[i];
66
          }
67
68
          //减少原来对oldkeys的引用计数
          DK_DECREF(oldkeys);
70
71
          //将ma values设置为NULL
72
           //因为所有的value都存在了PyDictKeyEntry对象的me_value里面
           mp->ma_values = NULL;
73
           if (oldvalues != empty_values) {
74
               free_values(oldvalues);
75
76
           }
77
       }
78
       // 否则的话说明这本身就是一个combined table
79
      else {
        //numentries等于mp->ma_used, 也就是键值对的个数
80
         //如果等于oldkeys->dk_nentries
81
        //证明没有dummy态的entry
82
          if (oldkeys->dk_nentries == numentries) {
83
           //那么直接将旧的entries拷贝到新的entries里面去
84
              memcpy(newentries, oldentries, numentries * sizeof(PyDictKe
86 yEntry));
87
          }
         //否则说明存在dummy态的entry
88
89
          else {
          //active态的entry搬到新table中
90
          //dummy态的entry则被丢弃
91
              PyDictKeyEntry *ep = oldentries;
              for (Py_ssize_t i = 0; i < numerities; i++) {</pre>
93
94
                 while (ep->me_value == NULL)
95
                     ep++;
                 newentries[i] = *ep++;
96
97
              }
98
           }
99
           //字典的缓存池操作, 后面介绍
100
           assert(oldkeys->dk_lookup != lookdict_split);
101
           assert(oldkeys->dk_refcnt == 1);
102
           if (oldkeys->dk_size == PyDict_MINSIZE &&
103
```

```
numfreekeys < PyDict_MAXFREELIST) {</pre>
104
               DK_DEBUG_DECREF keys_free_list[numfreekeys++] = oldkeys;
105
          }
106
           else {
107
108
               DK_DEBUG_DECREF PyObject_FREE(oldkeys);
           }
109
110
       }
111
      //建立哈希表索引
112
113
       build_indices(mp->ma_keys, newentries, numentries);
114
      mp->ma_keys->dk_usable -= numentries;
       mp->ma_keys->dk_nentries = numentries;
115
      return 0;
116
   }
```

## 代码虽然虽然有点长,但是逻辑很好理解:

- 首先要确定哈希表的大小,很显然这个大小一定要大于minsize。这个minsize我们已经看到了,是通过宏定义的,等于ma\_used的3倍;
- 根据新的table, 重新申请内存;
- 将原来的处于active态的entry拷贝到新的内存当中,而对于处于dummy态的entry则直接丢弃。可以丢弃的原因我们前面也说过了。因为哈希表扩容会申请的一个新的数组,直接将原来的active态的entry组成一条新的探测链即可,因此也就不需要这些dummy态的entry了。

以上就是哈希表的扩容,或者说字典的扩容,我们就介绍到这儿,下一篇来介绍字典的缓存池,这也是关于字典的最后一篇文章。



