# 《源码探秘 CPython》50. 剖析字节码指令,观测Python程序的执行过程

原创 古明地觉 古明地觉的编程教室 2022-03-16 08:30

收录于合集 #CPython

97个 >





这里我们通过问与答的方式回顾一下前面的内容,并介绍一些常见的字节码指令。

### 1) 请问 Python 程序是怎么运行的? 是编译成机器码后再执行的吗?

执行 Python 程序的虽然被称为 Python 解释器,但它其实包含一个编译器和一个虚拟机。

当我们在命令行敲下python xxxx.py时,Python解释器中的编译器首先登场,将源代码编译成PyCodeObject对象。PyCodeObject对象包含字节码、以及执行字节码时所需的名字以及常量。

当编译器完成编译动作后,接力棒便传给虚拟机,虚拟机负责维护执行上下文,逐条执行字节码指令。执行上下文中最核心的名字空间,便是由虚拟机负责维护的。

因此 Python程序的执行原理其实更像 Java,可以用两个词来概括:虚拟机和字节码。不同的是,Java的编译器javac与虚拟机java是分离的,而 Python 将两者整合成一个 python 命令。

# 2) pyc 文件保存什么东西,有什么作用?

Python源代码在执行时需要先由编译器编译成PyCodeObject对象,然后再交由虚拟机来执行。而不管程序执行多少次,只要源码没有变化,编译后得到的 PyCodeObject 对象就肯定是一样的。

因此,Python 将 PyCodeObject对象序列化并保存到pyc文件中。当程序再次执行时,Python 可以直接从pyc文件中加载,省去编译环节。当然了,如果源码文件发生改动,那么 pyc文件便会失效,这时必须重新编译 py 文件。

#### 3) 如何查看 Python程序的字节码?

Python 标准库中的 dis 模块,可以对 PyCodeObject对象以及函数进行反编译,并显示其中的字节码。

我们可以直接传入PyCodeObject对象, 当然也可以传入一个函数, 会自动获取其内部

的\_\_code\_\_。

#### 4) 介绍几个常见的字节码指令?

Python的字节码指令有120多个,但其中有几个太常见了,我们这里必须要提一下,然后再举例说明。

LOAD_CONST	加载一个常量
LOAD_FAST	在局部作用域(比如函数)中加载一个局部变量
LOAD_GLOBAL	在局部作用域(比如函数)中加载一个全局变量或者 内置变量
LOAD_NAME	在全局作用域中加载一个全局变量或者内置变量
STORE_FAST	在局部作用域中定义一个局部变量,来建立和某个 对象之间的映射关系
STORE_GLOBAL	在局部作用域中定义一个global关键字声明的全局 变量,来建立和某个对象之间的映射关系
STORE_NAME	在全局作用域中定义一个全局变量,来建立和某个对象之间的映射关系

宣言 古明地觉的 Python小屋

下面来实际操作一波,看看这些指令:

```
1 import dis
3 name = "古明地觉"
5 def foo():
     gender = "female"
     print(gender)
     print(name)
10 dis.dis(foo)
11
                                    1 ('female')
0 (gender)
              0 LOAD_CONST
13
              2 STORE_FAST
           4 LOAD_GLOBAL 0 (print)
              6 LOAD_FAST
                                      0 (gender)
17
              8 CALL_FUNCTION
             10 POP_TOP
            12 LOAD_GLOBAL
                                  0 (print)
             14 LOAD GLOBAL
                                      1 (name)
             16 CALL_FUNCTION
              18 POP_TOP
              20 LOAD_CONST
                                       0 (None)
              22 RETURN_VALUE
                                🏠 古明地觉的 Python小屋
```

- 0 LOAD\_CONST: 加载字符串常量 "female"。更准确的说,加载的应该是指向字符串常量的指针,但为了描述方便,我们就用常量代替了;
- 2 STORE\_FAST: 在局部作用域中定义一个局部变量gender, 和字符串对象 "female" 建立映射关系,本质上就是让变量 gender 保存这个字符串对象的地址;
- 4 LOAD\_GLOBAL: 在局部作用域中加载一个内置变量 print;
- 6 LOAD\_FAST: 在局部作用域中加载一个局部变量 gender;
- 14 LOAD\_GLOBAL: 在局部作用域中加载一个全局变量 name;

```
1 import dis
2
3 name = "古明地觉"
4
```

- 0 LOAD\_CONST: 加载字符串常量 "古明地恋";
- 2 STORE\_GLOBAL: 在局部作用域中定义一个被global关键字声明的 全局变量;

```
1 import dis
3 s = """
4 name = "古明地觉"
5 print(name)
7 # 以模块的方式进行编译
8 dis.dis(compile(s, "<file>", "exec"))
                              0 ('古明地觉')
            0 LOAD_CONST
            2 STORE_NAME
                                  0 (name)
12
             6 LOAD_NAME
8 CALL_FUNCTION
10 POP TOP
            4 LOAD NAME
                                  1 (print)
                                0 (name)
            6 LOAD_NAME
           10 POP_TOP
            12 LOAD CONST
```

- 0 LOAD\_CONST: 加载字符串常量 "古明地觉";
- 2 STORE\_NAME: 在全局作用域中定义一个全局变量 name, 并和上面的字符串对象进行绑定;
- 4 LOAD\_NAME: 在全局作用域中加载一个内置变量 print;
- 6 LOAD NAME: 在全局作用域中加载一个全局变量 name;

以上我们就通过代码实际演示了这些指令的作用,它们和常量、变量的加载,以及变量的定义密切相关,可以说常见的不能再常见了。你写的任何代码在反编译之后都少不了它们的身影,至少会出现一个,因此有必要提前解释一下。

不管加载的是常量、还是变量,得到的永远是指向对象的指针。

5) Python 在变量交换时有两种不同的写法,示例如下。这两种写法有什么区别吗?哪种写法更好?

```
1 # 写法一
2 a, b = b, a
3
4 # 写法二
5 tmp = a
6 a = b
7 b = tmp
```

这两种写法都能实现变量交换,并且从表面上看第一种写法更加简洁明了。但是优雅的外表下是否隐藏着不为人知的性能缺陷呢?想要找到答案,唯一的途径就是研究字节码:

```
2 LOAD NAME
                                         1 (a)
              4 ROT_TWO
              6 STORE NAME
                                         1 (a)
                                          0 (b)
              8 STORE NAME
# 写法二
              O LOAD NAME
                                         0 (a)
 1
             2 STORE_NAME
                                         1 (tmp)
              4 LOAD NAME
                                          2 (b)
 2
              6 STORE_NAME
                                          0 (a)
              8 LOAD_NAME
                                          1 (tmp)
                                  Thu 古明地觉的 Python小屋
             10 STORE NAME
```

其实不用看字节码也知道写法一的性能更优,但这里我们主要是想研究一下写法一背后的原理。从字节码可以看出,先通过LOAD\_NAME将变量b和a加载进来,压入运行时栈;调用ROT\_TWO指令;再将栈的元素依次弹出,赋值给a和b。

等号右边是 b, a, 所以先加载 b 后加载 a; 等号左边是 a, b, 所以先给 a 赋值、再给 b 赋值。因此无论是加载、还是赋值,都是从左往右进行的。

所以核心就在于 ROT\_TWO 这个指令, 我们来看看它都做了什么。

```
1 case TARGET(ROT_TWO): {
2 //获取栈顶元素,由于b先入栈、a后入栈
    //再加上栈是先入后出,所以这里获取的栈顶元素就是a
4
    PyObject *top = TOP();
5 //运行时栈的第二个元素就是b
   //TOP是查看栈顶元素、SECOND是查看栈的第二个元素
6
    //并且这两个函数只是获取, 不会将元素从栈中弹出
7
8  PyObject *second = SECOND();
    //将栈顶元素设置为 second, 这里显然就是变量 b
9
    //将栈的第二个元素设置为 top, 这里显然就是变量 a
10
  SET_TOP(second);
11
   SET_SECOND(top);
12
13
    FAST_DISPATCH();
14 }
```

因此执行完 ROT\_TWO 指令之后,栈顶元素就是 b,栈的第二个元素就是 a。然后,后面的两个 STORE\_NAME 会将栈里面的元素 b、a依次弹出,赋值给 a、b,从而完成变量交换。

因此 ROT\_TWO 指令只是将栈顶的两个元素交换位置,执行起来比 LOAD\_NAME 和 STORE\_NAME 都要快。至此我们可以得出结论了,第一种变量交换写法更优,原因如下:

- 代码简洁明了, 不拖泥带水;
- 不需要辅助变量 tmp, 节约内存;
- ROT\_TWO 指令比 LOAD\_NAME 和 STORE\_NAME 组成的指令对更有优势,执行效率更高;

#### 6) 聊一聊 a, b, c = c, b, a 这种赋值方式的背后原理。

老规矩, 查看字节码, 因为在字节码的面前没有秘密。

```
O LOAD NAME
                            0 (c)
 2 LOAD NAME
                            1 (b)
4 LOAD NAME
                            2 (a)
6 ROT_THREE
8 ROT_TWO
10 STORE NAME
                            2 (a)
12 STORE_NAME
                            1 (b)
14 STORE NAME
                            0 (c)
16 LOAD CONST
                            0 (None)
```

原理和 a, b = b, a 是类似的,首先 LOAD\_NAME 将变量 c、b、a 依次压入栈中。由于栈先入后出的特性,此时栈的三个元素按照顺序(从栈顶到栈底)分别是 a、b、c。

然后是 ROT\_THREE 和 ROT\_TWO,毫无疑问,这两个指令执行完之后,会将栈的三个元素调换顺序,也就是将 a、b、c 变成 c、b、a。

最后 STORE\_NAME 将栈的三个元素 c、b、a 依次弹出,分别赋值给 a、b、c,从而完成变量的交换。

因此核心就在 ROT\_THREE 和 ROT\_TWO 上面,由于后者我们已经见过了,所以我们看一下 ROT THREE。

```
1 case TARGET(ROT_THREE): {
2    PyObject *top = TOP();
3    PyObject *second = SECOND();
4    PyObject *third = THIRD();
5    SET_TOP(second);
6    SET_SECOND(third);
7    SET_THIRD(top);
8    FAST_DISPATCH();
9 }
```

栈顶元素是 top、栈的第二个元素是 second、栈的第三个元素是 third,然后将栈顶元素设置为 second、栈的第二个元素设置为 third、栈的第三个元素设置为 top。

所以栈里面的元素 a、b、c 在经过  $ROT_THREE$  之后就变成了 b、c、c, 显然这还不是正确的结果。于是继续执行  $ROT_TWO$ ,将栈的前两个元素进行交换,执行完之后就变成了 c、b、a。

## 7) 聊一聊 a, b, c, d = d, c, b, a 背后的原理, 和上面 6) 提到的变量交换有区别吗?

```
0 LOAD NAME
                                            0 (d)
                  2 LOAD NAME
                                             1 (c)
                 4 LOAD_NAME
                                            2 (b)
                 6 LOAD NAME
                                            3 (a)
                 8 BUILD_TUPLE
                                             4
                10 UNPACK SEQUENCE
                                             3 (a)
                 12 STORE NAME
                                             2 (b)
                14 STORE_NAME
                16 STORE NAME
                                             1 (c)
                                             0 (d)
                 18 STORE NAME
11
                 20 LOAD_CONST
                                             0 (None)
12
                22 RETURN_VALUE
                                    🏠 古明地觉的 Python小屋
13
```

仍是从左往右,将变量 d、c、b、a 依次压入栈中,但此时没有直接将栈里面的元素做交换,而是构建一个元组。因为往栈里面压入了四个元素,所以 BUILD\_TUPLE 后面的 oparg 是 4,表示构建长度为 4 的元组。

```
1 case TARGET(BUILD_TUPLE): {
2    PyObject *tup = PyTuple_New(oparg);
3
      if (tup == NULL)
4
         goto error;
   while (--oparg >= 0) {
5
6
         PyObject *item = POP();
7
         PyTuple_SET_ITEM(tup, oparg, item);
     }
8
9
     PUSH(tup);
10
    DISPATCH();
11 }
```

先申请一个长度为 4 的 PyTupleObject,然后元素依次出栈,被设置到元组中。注意代码中的 while 条件,显然元素是从后往前设置的,而元素的出栈顺序是 a b c d,因此循环结束之后,元组为 (d, c, b, a)。构建完,再将其压入栈中,此时运行时栈里面只有这一个元组(指针)。

接下来是 UNPACK SEQUENCE, 我们看看它做了什么?

```
case TARGET(UNPACK SEQUENCE): {
   PREDICTED (UNPACK SEQUENCE);
   PyObject *seq = POP(), *item, **items;
   if (PyTuple_CheckExact(seq) &&
       PyTuple_GET_SIZE(seq) == oparg) {
       items = ((PyTupleObject *)seq)->ob_item;
       while (oparg--) {
           item = items[oparg];
           Py_INCREF(item);
           PUSH(item);
   } else if (PyList_CheckExact(seq) &&
              PyList_GET_SIZE(seq) == oparg) {
       items = ((PyListObject *)seq)->ob_item;
       while (oparg--) {
           Py INCREF(item);
```

从名字上可以看出,这个指令用于对序列进行解包,由于元组、列表、以及其它可迭代 对象都属于序列,所以要进行类型判断。但这里我们只看元组部分,其它部分是类似 的。

首先代码中的 seq 就是从栈里面弹出的元组(指针),items 是元组内部的指针数组,存放了变量 dcba。注意了,然后还是从后往前遍历,将指向的对象的引用计数加1之后,再将变量压入栈中。循环结束之后,栈里面的元素按照顺序也是 dcba。

最后 STORE\_NAME 将 d c b a 依次弹出,赋值给变量 a b c d,从而完成变量交换。 所以,当交换的变量多了之后,不会直接在运行时栈里面操作,而是将栈里面的元素挨 个弹出、构建元组;然后再按照指定顺序,将元组里面的元素重新压到栈里面。

不管是哪一种做法,Python在进行变量交换时(多元赋值同理)所做的事情是不变的,核心分为三步走。首先固定按照从左往右的顺序,将等号右边的变量或常量依次压入栈中;然后,将运行时栈里面的元素进行翻转;最后,再将运行时栈里面的元素挨个弹出,固定按照从左往右的顺序依次赋值给等号左边的变量。

只不过当变量数量不多时,翻转元素会直接基于栈进行操作;而当达到四个时,则需要额外借助于元组。

#### 8) a, b, c, d = d, c, b, a 和 a, b, c, d = [d, c, b, a] 有区别吗?

答案是没有区别,两者在反编译之后对应的字节码指令只有一处不同。

```
O LOAD NAME
                                               0 (d)
                  2 LOAD NAME
                                               1 (c)
                  4 LOAD NAME
                                               2 (b)
                  6 LOAD_NAME
                                              3 (a)
                  8 BUILD LIST
                                              4
                 10 UNPACK SEQUENCE
                                              4
                                              3 (a)
                 12 STORE NAME
                 14 STORE NAME
                                               2 (b)
                                              1 (c)
                 16 STORE NAME
                                               0 (d)
                 18 STORE NAME
11
                 20 LOAD CONST
                                               0 (None)
12
                 22 RETURN_VALUE
                                     😘 古明地觉的 Python小屋
13
```

前者是 BUILD\_TUPLE, 现在变成了 BUILD\_LIST, 其它部分一模一样, 所以两者的效果是相同的。当然啦,由于元组的构建比列表快一些,因此还是推荐第一种写法。

#### 9) a = b = c = 123 背后的原理是什么?

如果变量 a、b、c 指向的值相同,比如都是 123,那么便可以通过该种方式进行赋值。那么它背后是怎么做的呢?

```
1 2 0 LOAD_CONST 0 (123)
2 DUP_TOP
3 4 STORE_NAME 0 (a)
4 6 DUP_TOP
5 8 STORE_NAME 1 (b)
6 10 STORE_NAME 2 (c)
7 12 LOAD_CONST 1 (None)
8 14 RETURN_VALUE 合用地觉的 Python小屋
```

出现了一个新的字节码指令 DUP TOP, 只要搞清楚它的作用, 事情就简单了。

所以 DUP\_TOP 干的事情就是将栈顶元素拷贝一份,再重新压到栈里面。另外,不管等号左边有多少个变量,模式都是一样的,我们以 a=b=c=d=e=123 为例:

```
O LOAD CONST
                                          0 (123)
                2 DUP_TOP
                4 STORE NAME
                                           0 (a)
                6 DUP_TOP
                8 STORE NAME
                                           1 (b)
                10 DUP TOP
               12 STORE_NAME
                                           2 (c)
               14 DUP TOP
               16 STORE NAME
                                           3 (d)
               18 STORE NAME
10
                                           4 (e)
               20 LOAD_CONST
                                           1 (None)
12
                22 RETURN_VALUE
                                   T明地觉的 Python小屋
13
```

将常量(指针)压入运行时栈,然后拷贝一份,赋值给 a;再拷贝一份,赋值给 b;再拷贝一份,赋值给 c;再拷贝一份,赋值给 d;最后自身赋值给 e。

以上就是链式赋值的秘密,其实没有什么好神奇的,就是将栈顶元素进行拷贝,再依次赋值。

## 10) 请解释一下 a is b 和 a == b 的区别?

is是对象标识符(object identity),用于判断两个变量是不是引用同一个对象,等价于id(a)==id(b) ;而==操作符则是判断两个变量所引用的对象是否相等,等价于调用魔法方法a.\_\_eq\_\_(b) 。并且==操作符可以通过 \_\_\_eq\_\_ 魔法方法进行覆写 (overriding),而is操作符无法覆写。

Python的变量在C看来只是一个指针,因此两个变量是否指向同一个对象,等价于 C 中的两个指

针是否相等;而Python的==,则需要调用PyObject\_RichCompare,来比较它们指向的对象所维护的值是否相等。

从字节码上看,这两个语句也很接近,区别仅在比较指令COMPARE\_OP的操作数上:

```
# a is b
      1
                  O LOAD NAME
                                                0 (a)
                                                1 (b)
                  2 LOAD NAME
                  4 COMPARE OP
                                                8 (is)
                  6 POP TOP
   # a == b
                  0 LOAD NAME
     1
                                                0 (a)
                   2 LOAD NAME
                                                1 (b)
                  4 COMPARE OP
                                      2 (==)
古明地觉的 Python小屋
11
                  6 POP_TOP
```

我们看到操作数一个是 8、一个是 2, 然后是 COMPARE OP 指令的背后逻辑:

```
1 case TARGET(COMPARE_OP): {
     // 弹出栈顶元素, 这里是 b
   PyObject *right = POP();
     // 显然 Left 就是 a
4
     // b 被弹出之后, 它成为新的栈顶
5
   PyObject *left = TOP();
6
     // 进行比较, 比较结果为 res
7
     PyObject *res = cmp_outcome(tstate, opang, left, right);
8
     // 减少 Left 和 right 引用计数
9
     Py_DECREF(left);
10
     Py_DECREF(right);
11
     // 将栈顶元素替换为 res
12
13
     SET_TOP(res);
   if (res == NULL)
14
15
        goto error;
     // 介绍 if 语句的时候说
16
     PREDICT(POP_JUMP_IF_FALSE);
17
   PREDICT(POP_JUMP_IF_TRUE);
18
19
     // 相当于 continue
     DISPATCH();
20
21 }
```

所以逻辑很简单,核心就在 cmp outcome 函数中。

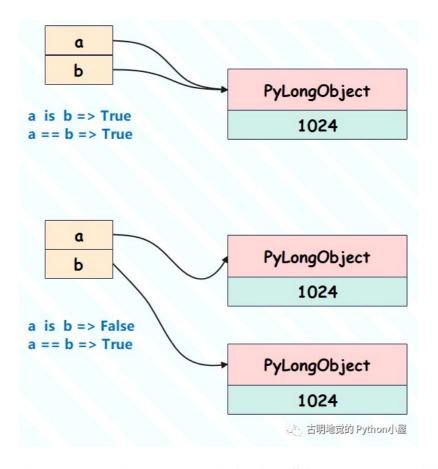
```
1 static PyObject *
2 cmp_outcome(int op, PyObject *v, PyObject *w)
3 {
     int res = 0;
4
     // op 就是 COMPARE_OP指令里面的操作数
5
     switch (op) {
6
     // PyCmp_IS 是一个枚举变量, 等于 8
7
     // 定义在 Include/opcode.h 中
8
     case PyCmp_IS:
9
      //is操作符, 在C的层面直接一个 == 判断即可
10
11
        res = (v == w);
        break;
12
13
   default:
14
     //而PyObject_RichCompare是一个函数调用
15
        //比较对象维护的值是否相等
16
17
        return PyObject_RichCompare(v, w, op);
     }
18
19
      v = res ? Py_True : Py_False;
     Py_INCREF(v);
20
21
      return v;
```

```
22 }
```

# 我们实际举个栗子:

```
1 >>> a = 1024
 2 >>> b = a
 3 >>> a is b
 5 >>> a == b
 6 True
 7 # a 和 b 引用同一个对象
 8 # is 和 == 操作均返回 True
9 >>>
10 >>>
11 >>> a = 1024
12 >>> b = int('1024')
13 >>> a is b
14 False
15 >>> a == b
16 True
17 # 显然引用的不是同一个对象, 因此 is 操作结果是 False
18 # 而对象的值相同, 因此 == 操作结果是 True
```

#### 用一张图看一下它们之间的区别:



一般而言,如果a is b成立,那么a == b大部分成立。可能有人好奇,a is b 成立说明 a 和 b 指向的是同一个对象,那么 a == b 表示该对象和自己进行比较,结果应该始终是相等的呀,为啥是大部分成立呢?以下面两种情况为例:

```
1 class Girl:
2
3    def __eq__(self, other):
4        return False
5
6    g = Girl()
7    print(g is g) # True
8    print(g == g) # False
```

eq 返回 False,此时虽然是同一个对象,但是两者不相等。

```
1 import math
2 import numpy as np
3
4 a = float("nan")
5 b = math.nan
6 c = np.nan
7
8 print(a is a, a == a) # True False
9 print(b is b, b == b) # True False
10 print(c is c, c == c) # True False
```

nan 是一个特殊的浮点数,意思是not a number (不是一个数字) ,用于表示空值。 不管 nan 跟任何浮点数(包括自身)做何种数学比较,结果均为 False。

但需要注意的是,在使用 == 进行比较的时候虽然是不相等的,但如果放到容器里面就不一定了。举个栗子:

```
1 import numpy as np
2
3 lst = [np.nan, np.nan, np.nan]
4 print(lst[0] == np.nan) # False
5 print(lst[1] == np.nan) # False
6 print(lst[2] == np.nan) # False
7 # lst 里面的三个元素和 np.nan 均不相等
8
9 # 但是 np.nan 位于列表中,数量为 3
10 print(np.nan in lst) # True
11 print(lst.count(np.nan)) # 3
```

出现以上结果的原因就在于,元素被放到了容器里,而容器的一些 API 在比较元素时会 先判定它们存储的对象的地址是否相同,即:是否指向了同一个对象。如果是,直接认 为相等;否则,再去比较对象维护的值是否相等。

可以理解为先进行 is 判断,如果结果为 True,直接判定两者相等;如果 is 操作的结果不为 True,再去进行 == 判断。

因此 np.nan in lst 的结果为 True, lst.count(np.nan)的结果是3,因为它们会先比较对象的地址。地址相同,直接认为对象相等。

在用 pandas 做数据处理的时候,nan 是一个非常容易坑的地方。

# 11) 在与 None 比较时,为什么要用 is 而不是 ==?

因为 == 可以被重载, 所以不应该用 == 去判断。

```
1 class Girl:
2   def __eq__(self, other):
3     return True
4
5   g = Girl()
6   print(g is None) # False
7   print(g == None) # True
```

而 None 是一种特殊的内建对象,它是单例的,整个运行的程序中只有一个,所以应该用 is 去判断。

另外 is 在底层只需要一个 == 操作符即可完成;但是Python的 == , 在底层则是需要调用PyObject\_RichCompare函数。因此 is None 在性能上也更有优势,再加上None 是单例对象,使用 is 判断再合适不过。

我们使用jupyter notebook测试一下两者的性能吧:

Otimoit name is None



文章已于2022-03-19修改

